

GUÍA CONCEPTUAL

Forecasting y primer modelo de máximo diario del SIN

Conceptos adquiridos e introducidos hasta la Sesión 3

Propósito del documento

Este PDF no es una bitácora de código. Es una guía de estudio conceptual: define, conecta e interpreta los conceptos de forecasting y aprendizaje automático que ya aparecieron en el trabajo práctico. Los números del experimento del SIN se usan como ejemplos para fijar ideas.

Fuentes académicas principales

Hyndman & Athanasopoulos, Forecasting: Principles and Practice (3rd ed.); Stanford CS229 / STATS 202; James et al., An Introduction to Statistical Learning; documentación oficial de scikit-learn; y el artículo del dataset del SIN.

Versión: 23 de septiembre de 2026

Cómo usar esta guía

La idea es poder volver a este documento antes de avanzar a modelos más complejos. Cada concepto aparece con cuatro preguntas: qué es, para qué sirve, cómo apareció en nuestro experimento y qué error de interpretación conviene evitar.

Estado	Significado
APRENDIDO	Lo usamos y lo interpretamos con resultados reales.
INTRODUCIDO	Ya apareció en la conversación o en el flujo de trabajo, pero todavía no lo desarrollamos en profundidad.

Mapa de conceptos vistos

- Formulación del problema: forecasting, serie temporal, frecuencia, horizonte, objetivo de pronóstico y pronóstico directo del máximo diario.
- Aprendizaje supervisado: X, y, features, target, ejemplos de entrenamiento, regresión y lags.
- Modelos de referencia: baseline y método naive.
- Evaluación: error, subestimación/sobreestimación, error absoluto, MAE y escalado relativo del MAE.
- Entrenamiento y generalización: train/test, orden temporal, fit, predict, error de entrenamiento y error de prueba.
- Regresión lineal: intercepto, pendiente, parámetros, mínimos cuadrados y comparación con el baseline.
- Preprocesamiento: fechas, zona horaria, duplicados, orden temporal, huecos y agregación horaria→diaria.

Fuentes base: [1], [2], [3], [4], [5]

1. Forecasting: qué problema estamos resolviendo

Forecasting (pronóstico) consiste en estimar valores futuros de una variable usando información disponible hasta un momento determinado. En una serie temporal el orden importa: una observación de mañana no debe utilizarse para construir una predicción hecha hoy. [1]

Serie temporal

Una serie temporal es una secuencia de observaciones asociadas a instantes o intervalos de tiempo. Nuestro dataset original contiene demanda eléctrica horaria del SIN; por eso, antes de transformar los datos, la frecuencia natural de la variable de demanda es horaria.

Origen del pronóstico

Es el instante hasta el cual suponemos que conocemos información. Si estamos al final del día t y queremos pronosticar el máximo del día siguiente, todo lo que usemos como entrada debe estar disponible hasta ese origen.

Horizonte de pronóstico

El horizonte indica cuántos pasos hacia el futuro queremos predecir. Se suele representar con h . En nuestro ejercicio, después de convertir la serie a frecuencia diaria, el horizonte es $h = 1$ día: usamos información hasta el día t para pronosticar el máximo del día $t+1$. [1]

$$h = 1 \text{ día}$$

Nuestro primer experimento: máximo diario del día siguiente.

Frecuencia y horizonte no son lo mismo

La frecuencia describe cada cuánto tenemos observaciones (horaria, diaria, mensual). El horizonte describe qué tan lejos hacia el futuro pronosticamos. Nosotros partimos de datos horarios, los agregamos a máximos diarios y luego pronosticamos un día adelante.

Pronóstico directo del máximo diario

No es obligatorio pronosticar las 24 horas para luego tomar el mayor valor. Podemos definir directamente como objetivo el máximo del día siguiente. Esto convierte el problema en una predicción diaria de una variable continua. La contrapartida es que un modelo que solo pronostica la magnitud del máximo no determina automáticamente a qué hora ocurrirá.

Idea clave

La variable que decidimos pronosticar define el problema. “Demanda horaria de mañana” y “máximo diario de mañana” son objetivos distintos, aunque usen el mismo dataset.

Fuentes base: [1], [5]

2. Aprendizaje supervisado: X, y y ejemplos

En aprendizaje supervisado se dispone de ejemplos donde conocemos las entradas y la respuesta correcta. El algoritmo utiliza esos pares para aprender una función capaz de producir predicciones para nuevas entradas. Stanford CS229 formaliza este esquema con variables de entrada x y una variable objetivo y . [2]

Variable objetivo (target) - y

Es la cantidad que queremos predecir. En nuestro primer modelo, y es SIN_max : el máximo de demanda del día que queremos pronosticar.

Variables de entrada (features) - X

Son los datos que entregamos al modelo para construir la predicción. En el primer ejercicio usamos una sola feature: MAX_AYER .

$$X = [MAX_AYER] \quad y = SIN_max$$

Ejemplo de entrenamiento

Una fila útil para el aprendizaje contiene una entrada y su respuesta real. Por ejemplo, para el 02/01/2008 usamos como X el máximo del 01/01/2008 (1251.0 MW) y como y el máximo real del 02/01/2008 (1440.6 MW).

Regresión

Cuando la variable objetivo es numérica y continua, el problema se denomina regresión. Como SIN_max se expresa en MW y puede tomar muchos valores continuos, nuestro problema es de regresión, no de clasificación. [2]

Información disponible al momento de pronosticar

Una feature es válida para un pronóstico real solo si puede conocerse cuando se emite ese pronóstico. Usar información futura produciría una evaluación artificialmente buena. En forecasting, esta restricción temporal es central; Hyndman & Athanasopoulos distinguen explícitamente pronósticos que usan únicamente información disponible de antemano. [1]

Regla práctica

Antes de agregar una nueva feature, preguntar: “¿Conozco este valor en el instante en que hago el pronóstico?” Si la respuesta es no, no puede usarse directamente en un pronóstico ex-ante.

Fuentes base: [1], [2]

3. Lags: convertir el pasado en una entrada

Un lag es un valor pasado de una variable usado como predictor de un valor posterior. En series temporales, los lags permiten incorporar memoria del pasado dentro de un modelo de regresión. [1]

Lag 1

MAX_AYER es un lag de un día del máximo diario. Si llamamos y_t al máximo del día t , entonces MAX_AYER representa $y_{(t-1)}$.

$$\text{lag 1: } X_t = y_{(t-1)}$$

Qué hizo shift(1)

La operación shift(1) desplazó la columna SIN_max una fila hacia abajo. Así, cada fila del día t recibió como entrada el máximo del día anterior. La primera fila quedó con NaN porque el dataset no contiene el día anterior al inicio de la muestra.

Por qué descartamos ese NaN

No lo reemplazamos por cero ni inventamos un dato. Simplemente ese primer día no puede convertirse en un ejemplo con lag 1 porque no existe $y_{(t-1)}$ dentro del período disponible. Por eso se excluye de datos_modelo y quedan 5478 ejemplos utilizables a partir de 5479 días.

Lags adicionales

También mencionamos MAX_7_DIAS: sería un lag 7, es decir, el máximo observado siete días antes. Todavía no lo incorporamos al modelo; solo introdujimos la idea de que una serie puede ofrecer múltiples lags como features.

Fuentes base: [1]

4. Baseline y modelo naive

Antes de usar un algoritmo más complejo conviene tener una referencia sencilla. Esa referencia se denomina baseline o benchmark. Si un modelo sofisticado no supera una regla simple en datos de prueba, su complejidad no está aportando una mejora demostrada.

Método naive

El método naive de un paso usa la última observación disponible como pronóstico de la siguiente. En nuestro problema diario, pronostica que el máximo de mañana será igual al máximo de hoy. FPP3 utiliza los métodos naive como referencias fundamentales de forecasting. [1]

$$\hat{y}_t = y_{(t-1)}$$

En nuestro DataFrame: PREDICCIÓN = MAX_AYER.

Por qué es útil aunque “no aprenda”

El naive no ajusta parámetros con fit(). Sin embargo, produce pronósticos reales y puede evaluarse sobre el mismo período que cualquier otro modelo. Por eso nos da una vara mínima contra la cual comparar.

Resultado obtenido

Conjunto	MAE naive
Entrenamiento	129.39 MW
Prueba	188.60 MW

El valor de prueba, 188.60 MW, se convirtió en nuestro benchmark principal para la comparación con la regresión lineal.

Fuentes base: [1]

5. Error de pronóstico y MAE

Evaluar significa comparar lo que el modelo pronosticó con lo que realmente ocurrió. Un pronóstico no se juzga por “parecer razonable”, sino por una medida de error definida antes de comparar modelos.

Error de pronóstico

Adoptamos la convención usada en FPP3: error = valor real - valor pronosticado. [1]

$$e_t = y_t - \hat{y}_t$$

Signo de e	Interpretación
$e > 0$	El valor real fue mayor: el modelo subestimó.
$e < 0$	El valor real fue menor: el modelo sobreestimó.
$e = 0$	Predicción exacta.

Error absoluto

El valor absoluto $|e_t|$ elimina el signo y conserva únicamente la magnitud del error. Evita que una sobreestimación y una subestimación de igual tamaño se cancelen al promediar.

MAE - Mean Absolute Error

$$MAE = \text{promedio}(|y_t - \hat{y}_t|)$$

El MAE resume en un solo número la magnitud media de los errores. Conserva las unidades de la variable objetivo; por eso nuestro MAE se expresa en MW. El mejor valor posible es 0. [1][4]

Interpretación de nuestro resultado

MAE naive = 188.60 MW significa que, en los 1096 días de prueba, la magnitud promedio del error del pronóstico naive fue 188.60 MW. No significa que todos los días se equivocó exactamente esa cantidad.

MAE relativo que calculamos

Dividimos el MAE naive (188.60 MW) por el máximo diario promedio del test (2662.36 MW) y obtuvimos 7.08 %. Este número sirve como una escala relativa para nuestro ejercicio, pero no debe confundirse con MAPE ni presentarse como una definición universal de “nMAE” sin especificar el denominador.

$$188.60 / 2662.36 \times 100 = 7.08 \%$$

MAE no es MAPE

MAPE calcula primero un error porcentual para cada observación y luego promedia esos porcentajes. Nosotros hicimos otra operación: dividimos un único MAE por un único promedio de demanda. Son métricas distintas. [1]

Fuentes base: [1], [4]

6. Entrenamiento, prueba y generalización

La precisión que realmente interesa es la obtenida sobre datos que no participaron en el ajuste. FPP3, ISLR y Stanford enfatizan esta separación entre error de entrenamiento y error de prueba. [1][2][3]

Conjunto de entrenamiento (train)

Contiene los ejemplos utilizados para estimar los parámetros de un modelo. En nuestro split 80/20 quedaron 4382 ejemplos antiguos para entrenamiento.

Conjunto de prueba (test)

Contiene datos posteriores que no se usan para ajustar la regresión. Quedaron 1096 ejemplos, comenzando en 2020. El test intenta aproximar cómo se comportará el modelo frente a información no vista durante el entrenamiento.

Por qué la división fue cronológica

En forecasting no conviene mezclar aleatoriamente pasado y futuro porque el escenario real es direccional: se aprende con el pasado y se predice lo posterior. Los procedimientos de validación temporal también preservan esta condición. [1]

Generalización

Es la capacidad del modelo de mantener un buen desempeño en ejemplos no vistos. Un error de entrenamiento bajo no garantiza un error de prueba bajo. Stanford define precisamente la generalización en términos del desempeño sobre ejemplos de test no vistos. [2]

Nuestros cuatro MAE

Modelo	MAE train	MAE test
Naive	129.39 MW	188.60 MW
Regresión lineal	129.11 MW	195.55 MW

La regresión lineal apenas mejoró el MAE del naive en entrenamiento (0.28 MW), pero obtuvo un MAE mayor en prueba (6.95 MW más). Esto muestra por qué mirar solo el ajuste sobre train puede ser engañoso.

No afirmamos todavía que exista sobreajuste

La diferencia train-test es una señal que debemos estudiar, pero un único experimento con un modelo de dos parámetros no basta para diagnosticar “overfitting”. También pueden intervenir cambios en la demanda a lo largo del tiempo, diferencias de escala, eventos atípicos o features insuficientes.

Fuentes base: [1], [2], [3]

7. Regresión lineal: qué aprende el modelo

La regresión lineal modela la respuesta como una combinación lineal de las variables de entrada. Con una sola feature, la predicción tiene la forma de una recta. [2][3]

$$\hat{y} = a + bX$$

Parámetros

a (intercepto) y b (pendiente) son parámetros aprendidos a partir del conjunto de entrenamiento. No son features y no los escribimos manualmente.

Pendiente

La pendiente indica cuánto cambia la predicción cuando X aumenta una unidad, manteniendo el resto fijo. Nuestro modelo aprendió $b = 0.908054$. Interpretado localmente: si MAX_AYER aumenta 100 MW, la predicción lineal aumenta aproximadamente 90.81 MW.

Intercepto

El modelo aprendió $a = 176.7815$ MW. Matemáticamente es la predicción cuando $X = 0$, pero ese escenario está lejos del rango normal del SIN; por eso no conviene atribuirle una interpretación física directa.

Nuestra ecuación ajustada

$$\hat{y} = 176.78 + 0.9081 \times \text{MAX_AYER}$$

fit()

`fit(X_train, y_train)` estima los parámetros usando los ejemplos de entrenamiento. En nuestro caso, al terminar `fit()` quedaron definidos el intercepto y la pendiente.

predict()

`predict(X_test)` no vuelve a entrenar. Aplica la relación ya aprendida a nuevas entradas para producir predicciones.

Mínimos cuadrados

La implementación `LinearRegression` de `scikit-learn` corresponde a mínimos cuadrados ordinarios. El ajuste busca coeficientes que minimicen la suma de los residuos al cuadrado en entrenamiento. Por eso el criterio de entrenamiento no es exactamente el MAE que luego usamos para evaluar. [4]

$$\min \sum (y_i - \hat{y}_i)^2$$

Objetivo de mínimos cuadrados ordinarios.

Fuentes base: [2], [3], [4]

8. Comparar modelos de forma justa

Una comparación solo es interpretable si los modelos se evalúan bajo condiciones equivalentes. En nuestro ejercicio, naive y regresión lineal usaron la misma variable disponible (MAX_AYER) y los mismos 1096 días de prueba.

Resultado principal de la Sesión 3

Modelo	MAE test	Diferencia vs naive
Naive	188.60 MW	Referencia
Regresión lineal	195.55 MW	+6.95 MW

Con la métrica MAE y este período de test, el naive obtuvo menor error promedio. Esto no demuestra que la regresión lineal sea “mala”; demuestra que, con una sola feature (MAX_AYER) y esta configuración, el ajuste lineal no aportó una mejora fuera de muestra.

Entrenar no equivale a mejorar

Un algoritmo puede encontrar parámetros que optimicen su objetivo sobre train y aun así no superar un baseline en test. El propósito del test es precisamente detectar esta situación.

Métrica y objetivo de entrenamiento pueden diferir

La regresión lineal ordinaria ajustó cuadrados de errores; nosotros elegimos MAE para interpretar el desempeño. Diferentes funciones de pérdida y métricas enfatizan distintos tipos de error. Esta distinción será importante más adelante en la tesis, especialmente al estudiar picos y subestimaciones.

Fuentes base: [1], [2], [4]

9. Preprocesamiento: conceptos que aparecieron antes del modelo

Aunque pausamos el análisis detallado de los huecos, varios conceptos de preparación de datos ya fueron introducidos y forman parte del flujo correcto de forecasting.

Parsing de fechas y zona horaria

Convertimos DATETIME a una representación temporal interpretable por pandas, primero en UTC y luego en America/Asuncion. La zona horaria importa porque nuestro objetivo “máximo diario” depende de qué horas pertenecen al mismo día local.

Duplicados

Encontramos 15 filas completamente duplicadas y las eliminamos. Un duplicado exacto no aporta una nueva observación; si se mantiene puede dar peso doble a ese registro.

Orden cronológico

Después de limpiar duplicados ordenamos por tiempo. Operaciones como shift(1), separación train/test y cualquier lag presuponen un orden temporal correcto.

Huecos o discontinuidades temporales

Detectamos saltos y revisamos el artículo del dataset, que documenta discontinuidades intencionales relacionadas con los cambios estacionales de horario de Paraguay. Decidimos pausar el tratamiento definitivo y no inventar valores faltantes. [5]

Agregación temporal

Transformamos la serie horaria en una serie diaria mediante el máximo de SIN para cada fecha local. Esa agregación cambió la unidad de observación: de “una fila = una hora” a “una fila = un día”. Obtuvimos 5479 días.

Máximo observado vs máximo verdadero

Si un día tiene huecos horarios, el máximo calculado con los registros disponibles es el máximo observado. No siempre podemos demostrar que coincide con el máximo que habría resultado con cobertura completa. Esta limitación debe resolverse antes de usar el experimento como evidencia final de tesis.

Fuentes base: [5]

10. Mapa mental del proceso completo visto hasta ahora

El siguiente esquema resume la lógica conceptual, no el código específico:

Etapas	Pregunta que responde	Lo que hicimos
1. Definir objetivo	¿Qué quiero pronosticar?	Máximo diario del SIN del día siguiente.
2. Preparar datos	¿Qué observaciones son válidas y comparables?	Fechas, duplicados, orden, agregación diaria.
3. Construir X e y	¿Qué sabe el modelo y qué debe predecir?	X = MAX_AYER; y = SIN_max.
4. Baseline	¿Qué logra una regla sencilla?	Naive: mañana = hoy.
5. Split temporal	¿Con qué aprendo y con qué compruebo?	4382 train, 1096 test.
6. Entrenar	¿Qué relación aprende el algoritmo?	Regresión lineal: a y b con fit().
7. Predecir	¿Qué produce sobre datos nuevos?	predict(X_test).
8. Evaluar	¿Cuánto se equivoca?	MAE y comparación con naive.
9. Interpretar	¿Mejoró realmente?	No: MAE test lineal > naive.

Resultado conceptual más importante

Un modelo no se valida porque “aprendió” o porque ajustó una ecuación. Se valida comparando

pronósticos sobre datos no usados para entrenar, mediante una métrica definida y contra referencias razonables.

11. Glosario de términos vistos

Término	Definición breve
Forecasting	Estimación de valores futuros usando información disponible hasta un origen de pronóstico.
Serie temporal	Observaciones ordenadas en el tiempo.
Frecuencia	Separación temporal natural entre observaciones: horaria, diaria, etc.
Horizonte h	Cantidad de pasos hacia el futuro que se desea pronosticar.
Target / y	Variable objetivo que se desea predecir.
Feature / X	Variable de entrada entregada al modelo.
Ejemplo de entrenamiento	Par entrada-respuesta usado para aprender.
Regresión	Aprendizaje supervisado con una salida numérica continua.
Lag	Valor pasado usado como predictor de un valor posterior.
Naive	Método que usa una observación pasada como pronóstico de la siguiente.
Baseline / benchmark	Referencia sencilla contra la que se compara un modelo.
Predicción / y_{hat}	Valor estimado por el modelo.
Error	Diferencia entre valor real y pronosticado.
MAE	Promedio del valor absoluto de los errores.
Train	Datos usados para estimar parámetros.
Test	Datos reservados para evaluar fuera de muestra.
Generalización	Capacidad de funcionar bien en datos no vistos durante el ajuste.
Parámetro	Cantidad aprendida por el modelo, como intercepto y pendiente.

fit()	Operación que ajusta los parámetros del modelo a los datos de entrenamiento.
predict()	Operación que aplica el modelo ya ajustado a nuevas entradas.
Mínimos cuadrados	Criterio que penaliza cuadrados de residuos y se usa en regresión lineal ordinaria.
Agregación temporal	Transformación de una frecuencia a otra resumiendo observaciones; aquí, horario → máximo diario.
NaN	Indicador de valor no disponible; no significa cero.

12. Conceptos introducidos pero todavía no desarrollados

Estos términos ya aparecieron en la conversación y conviene reconocerlos, pero no los consideramos “cerrados” todavía:

Concepto	Qué sabemos por ahora	Estado
Lag 7 / MAX_7_DIAS	Usar el máximo de hace siete días como nueva feature para capturar información semanal.	Pendiente de aplicar
Feature engineering	Construir predictores útiles a partir de historia, calendario o meteorología.	Introducido
Variables calendarias	Día de semana, feriado, mes, estación, etc. Pueden conocerse de antemano.	Introducido
Variables meteorológicas	Temperatura, humedad, etc.; para un pronóstico real deben estar disponibles o ser pronosticadas.	Introducido
Validación temporal	Conjunto o procedimiento adicional para elegir configuraciones sin “gastar” el test final.	Introducido
Cross-validation temporal	Evaluación con múltiples orígenes de pronóstico manteniendo siempre pasado→futuro.	Mencionado
Overfitting	Modelo demasiado adaptado a	Introducido

	entrenamiento que no generaliza bien. Aún no lo diagnosticamos en nuestro experimento.	
RMSE / MAPE	Otras métricas de error con propiedades distintas al MAE.	Mencionadas
Modelos más complejos	Regresión polinomial, Random Forest, XGBoost, etc. No se estudian aún en esta guía.	Pendiente

Fuentes base: [1], [2], [3]

13. Preguntas de autoevaluación

1. ¿Cuál es la diferencia entre frecuencia de una serie y horizonte de pronóstico?
2. ¿Por qué nuestro problema actual tiene horizonte $h = 1$ día?
3. ¿Cuál es la variable X y cuál es la variable y en el primer modelo?
4. ¿Por qué el problema es de regresión y no de clasificación?
5. ¿Qué significa lag 1 en nuestra serie de máximos diarios?
6. ¿Por qué la primera fila quedó con NaN después de `shift(1)`?
7. ¿Qué pronostica exactamente el método naive?
8. ¿Por qué necesitamos un baseline?
9. Con la convención $e = \text{real} - \text{pronosticado}$, ¿qué indica un error positivo?
10. ¿Qué mide el MAE y en qué unidades queda expresado?
11. ¿Por qué el 7.08 % que calculamos no es MAPE?
12. ¿Cuál es la diferencia conceptual entre `fit()` y `predict()`?
13. ¿Por qué separamos train y test?
14. ¿Qué significa generalizar?
15. ¿Por qué un MAE bajo en entrenamiento no garantiza un MAE bajo en prueba?
16. ¿Qué representan a y b en $\hat{y} = a + bX$?
17. ¿Qué función minimiza la regresión lineal ordinaria y por qué no coincide exactamente con MAE?
18. ¿Qué modelo obtuvo menor MAE en test en nuestro experimento?
19. ¿Podemos afirmar que la regresión lineal “fracasó” por ese resultado? ¿Por qué?
20. ¿Qué condición temporal debe cumplir cualquier nueva feature que agreguemos a un pronóstico real?

Criterio de dominio

Si podés responder estas preguntas sin mirar el código, ya entendés el núcleo conceptual del primer experimento.

14. Hoja de referencia rápida: nuestros números

Elemento	Valor
Filas originales del CSV	131481
Columnas originales	9
Duplicados exactos detectados	15
Filas tras eliminar duplicados	131466
Días obtenidos al agregar máximos	5479
Ejemplos utilizables con lag 1	5478
Train (80 %)	4382
Test (20 %)	1096
Inicio del test	2020-01-01
Máximo diario promedio del test	2662.36 MW
MAE naive - train	129.39 MW
MAE naive - test	188.60 MW
MAE relativo naive vs promedio test	7.08 %
Intercepto regresión lineal	176.7815 MW
Pendiente regresión lineal	0.908054
MAE lineal - train	129.11 MW
MAE lineal - test	195.55 MW
Diferencia lineal vs naive en test	+6.95 MW (lineal mayor)

Estos valores pertenecen al ejercicio didáctico actual. El tratamiento definitivo de discontinuidades temporales y la metodología final de tesis siguen pendientes.

15. Fuentes académicas y técnicas utilizadas

[1] Hyndman, R. J. & Athanasopoulos, G. Forecasting: Principles and Practice, 3rd edition. OTexts. Secciones utilizadas: evaluación de precisión (training/test, error, MAE), validación temporal, predictores con lags y forecasting con regresión.

- [2] Stanford University, CS229 / STATS 202 course notes. Temas utilizados: aprendizaje supervisado, variables de entrada y objetivo, regresión, error de predicción y generalización.
- [3] James, G., Witten, D., Hastie, T. & Tibshirani, R. An Introduction to Statistical Learning, 2nd edition. Springer, 2021. Temas utilizados: regresión lineal, distinción entre training error y test error, evaluación fuera de muestra.
- [4] scikit-learn User Guide / API documentation. LinearRegression (ordinary least squares) y mean_absolute_error. Fuente técnica primaria para el comportamiento de las funciones usadas en Colab.
- [5] Morales-Mareco, F., Verdún, M., Stalder, D. H., Sauer, C. & Grillo, S. “Electricity demand from national interconnected system of Paraguay and meteorological dataset”. Data in Brief, 61 (2025), 111782. DOI: 10.1016/j.dib.2025.111782. Fuente primaria del dataset del SIN.

Nota sobre fuentes

Las definiciones y principios se apoyan prioritariamente en libros de forecasting/estadística, apuntes universitarios y documentación oficial. Los números específicos del experimento (MAE, parámetros, tamaños de train/test) provienen de las ejecuciones realizadas durante nuestras sesiones de Colab y se usan aquí con fines de estudio.